

# Çoklu Robot Görev Atama için Adaptif Heuristic Ekosistemi:

## Arıza, Karışık Stres ve Deadline Baskısı Altında Çevrim İçi Tahsis

### Abstract

Bu çalışmada, robot arızaları, karışık stres ve deadline baskısı altında çevrim içi çoklu robot görev atama (MRTA) için bir Adaptif Heuristic Ekosistemi çerçevesi olan AHE-MRTA önerilmektedir. Tek bir tahsis paradigmasına bağlı kalmak yerine AHE-MRTA, Ekosistem-Güdümlü Paradigma Seçimi (EDPS) ile çalışma zamanında *paradigma değiştirir*: beş biyomimetik hormon (uzamsal, kritiklik, zamansal, kararlılık, toparlanma) beş klasik tahsis ilkeline eşlenir ve her olayda aktif ilke iki katmanlı bir kuralla seçilir—akut rejimler (arıza, deadline baskısı) için hızlı belirlenimci bağlam geçersiz-kılmaları (override) ve kalan olaylar için işbirliği/baskılama hormon dinamiği. AHE-MRTA'yı üç güncel temel yöntemle (BiG-MRTA, RoSTAM-EA, Consensus-DBTA) iki tamamlayıcı rejimde karşılaştırıyoruz: (i) algoritmik karar kalitesini fiziksel yürütme gürültüsünden yalıtın 100-tohumlu, Nav2-bağımsız bir tahsis-uygunluk simülâtörü ve (ii) üç fiziksel ölçekte (ROS 2 Jazzy Nav2 yığını çalıştıran 3, 5 ve 10 TurtleBot3 robotu) 300-deneylik bir Gazebo Harmonic kıyaslaması. Simülâtörde AHE-MRTA karışık stres altında birinci, robot arızasında birincilik için en iyi konsensüs temel yöntemiyle eşit ve deadline baskısında en iyi temel yöntemle beraberdir. Fiziksel yığında AHE-MRTA, 5 ve 10 robot ölçeklerinde robot arızası altında sıfıra-yakın deadline ihlaliyle tamamlamada öne geçer ( $CR = 1.000/0.996$ ,  $DVR = 0.008/0.024$ ); 10 robotta her senaryoda en yüksek tamamlama oranına ulaşır ( $CR = 0.996-1.000$ ) ve en düşük havuzlanmış makespan'ı elde eder. Konsensüs ve evrimsel temel yöntemler, deadline baskısı altında onun tamamlamasına yalnızca  $\approx 1.9 \times$  daha yüksek deadline ihlal oranıyla erişir ( $DVR = 0.38-0.49$  vs. AHE'nin  $0.24$ 'ü). Karar gecikmesi tüm ölçeklerde  $0.48$  ms'nin altında kalır; evrimsel temel yöntemden  $\approx 125-280 \times$  daha hızlıdır. İdeal-tahsis kazanımlarının Nav2 üzerinden neden doğrusal aktarılmadığını çözümlüyor ve paradigma değiştirmenin hangi koşullarda işe yaradığını belirliyoruz.

### Index Terms

Çoklu robot sistemleri, görev atama, çevrim içi algoritmalar, biyomimetik optimizasyon, ROS 2, Gazebo.

### I. GİRİŞ

Çoklu robot görev atama (MRTA), gelen görev akışını bir robot takımına bir görev hedefini karşılayacak biçimde dağıtır; denetim, teslimat, gözetleme ve arama-kurtarma uygulamalarının temelini oluşturur [1], [2]. Tek-görev, tek-robot, anlık atama biçimi bile NP-zordur [3]; saha işletimi ise statik bir atamanın soğuramayacağı üç baskı ekler: robotlar beklenmedik şekilde arızalanır, görev akışı aciliyet ve uzamsal yoğunlukta durağan değildir ve birçok görev ihlali maliyetli sert deadline'lar taşır [4], [5].

Güncel çevrim içi MRTA çözücülerinin her biri *tek* bir tahsis paradigmasına bağlanır ve her paradigma bir gücü bir zayıflıkla takas eder. Pazar- ve ihale-tabanlı yöntemler görevleri robotlara düşük gecikme ve sağlamlıkla teklif eder, ancak durum değiştiğinde yeniden-teklif bedeli öder [6]–[8]. Eşleme-, programlama- ve öngörü-tabanlı yöntemler (bipartit eşleme, doğrusal veya dışbükey programlar, geri-çekilen ufuk denetimi) yüksek kaliteli planlar üretir ama yeniden-planlama sıklığıyla kötü ölçeklenir [2], [9], [10]. Uzlaşma- ve demet-tabanlı yöntemler çok kararlı atamalar verir ama rejim değişince yavaş uyum sağlar [11]. Evrimsel ve öğrenme-tabanlı yöntemler daha zengin bir atama uzayını keşfeder ama ani bağlam değişimlerine yavaş tepki verir [12]. Hiçbir tekil paradigma heterojen, zamanla-değişen stres altında baskın değildir.

Doğru yapının *daha iyi bir tekil paradigma* değil, güncel bağlama ve yakın geçmiş performansla göre *paradigmalar arasında çevrim içi geçiş yapan ikeli bir mekanizma* olduğunu savunuyoruz. Bunu AHE-MRTA olarak somutlaştırıyoruz: beş hormonun bağlam sinyallerini izlediği, işbirliği ve baskılama dinamikleriyle evrildiği ve her yeniden planlama olayında beş klasik tahsis ilkelinden birini seçtiği biyomimetik bir ekosistem. Hormon-paradigma eşlemesi öğrenilmez, açıklanabilir (baskın hormon aktif davranışı adlandırır) ve hafiftir (milisaniye-altı karar gecikmesi). İkinci, yöntemsel bir katkı, robotik kıyaslamalarda tekrar eden bir güçlükten doğar: navigasyon maliyeti atama kadar dünya geometrisine de bağlı olduğundan, tahsis kalitesi ile fiziksel yürütme iç içe geçer [2]. Bunları navigasyon-bağımsız bir uygunluk simülâtörü ile tam bir ROS 2 Nav2 yığını kullanarak ayırıyoruz; bu ikisi birlikte, paradigma değiştirmenin nerede yardımcı olduğunu ve fiziksel yürütmenin kazanımları nerede sildiğini açıkça gösterir.

### Katkılar:

- 1) *Ekosistem-Güdümlü Paradigma Seçimi (EDPS)*: beş biyomimetik hormonu beş tahsis mekanizmasına eşleyen çevrim içi paradigma-değiştiren bir MRTA çerçevesi. Seçim iki katmanlıdır: akut rejimleri (robot arızası, deadline baskısı) hızlı belirlenimci bağlam geçersiz-kılmaları, kalan daha düşük-baskılı olayları ise Lotka–Volterra tipi hormon dinamiği ( $\arg \max_i D_i$ ) çözer. Eşleme sabit, açıklanabilir ve milisaniye-altıdır (Bölüm III).
- 2) *Nav2-bağımsız tahsis-uygunluk değerlendirme*: algoritmik karar kalitesini Nav2 yürütme gürültüsünden yalıtan idealize bir simülatör; senaryo başına 100 tohum üzerinden uygunluk raporlanır (Bölüm V).
- 3) *Tam Gazebo Harmonic + ROS2 Jazzy Nav2 doğrulaması*: üç stres senaryosu ve üç fiziksel ölçekte (3, 5 ve 10 robot) 300 deney; dört yöntem tamamlama oranı, deadline ihlali, toparlanma süresi, iş yükü dengesi, yürütme kesintileri, görev yeniden-gönderim oranı ve karar gecikmesi üzerinden karşılaştırılır (Bölüm VI).
- 4) *SIM-Gazebo aktarım açığının dürüst raporlanması*: paradigma değiştirmenin nerede yardımcı olduğunu (tamamlama oranı, deadline dayanıklılığı, tahsis kararlılığı) ve nerede maliyet getirdiğini (görev gecikmesi, toparlanma süresi, arızada makespan) belgeler ve mekanizmayı açıklarız (Bölüm VII).

## II. PROBLEM TANIMI

**Kümeler ve değişkenler.**  $\mathcal{R} = \{r_1, \dots, r_n\}$  robot kümesi ve  $\mathcal{T}(t)$   $t$  anındaki açık görev kümesi olsun; her görev  $\tau \in \mathcal{T}(t)$  bir 2B konum  $p_\tau$ , deadline  $d_\tau$ , öncelik  $\pi_\tau \in \{1, 2, 3\}$  ve yetenek gereksinimi  $c_\tau$  taşır. Her robot  $r$ , konum, batarya, mevcut görev ve uygunluk bayrağını (canlı / arızalı) kodlayan  $s_r(t) = (p_r, b_r, \tau_r^{\text{cur}}, \phi_r)$  durumuna sahiptir.

**Karar.** Her tahsis olayında  $t_k$  (arıza, görev gelişi, deadline alarmı, yeniden planlama zamanlayıcısı) politika, kardinalite kısıtı  $\sum_\tau x_{r,\tau} \leq Q$  (robot başına kuyruk üst sınırı) ve yetenek uygunluğu  $x_{r,\tau} = 1 \Rightarrow c_\tau \subseteq \text{cap}(r)$  ile bir atama  $x_{r,\tau}(t_k) \in \{0, 1\}$  üretir.

**Maliyet.** Çift başına maliyet seyahat süresi  $T_{r,\tau}$ , aciliyet  $u_\tau = (d_\tau - t_k)^{-1}$ , kritiklik  $\pi_\tau$ , enerji boşluğu  $e_{r,\tau}$  ve yakın yeniden-atama cezasını  $\rho_{r,\tau}$  birleştirir:

$$C_{r,\tau} = w_d T_{r,\tau} + w_u u_\tau^{-1} + w_\pi \pi_\tau^{-1} + w_e e_{r,\tau} + w_\rho \rho_{r,\tau}, \quad (1)$$

burada ağırlık vektörü  $w$ ,  $t_k$ 'da seçilen paradigma tarafından üretilir (Bölüm III). Aciliyet terimi, halihazırda kendi sahibi robotun kuyruğunda fizibil olan bir görev için taban değerinde tutulur; böylece yaklaşan bir deadline *atanmamış* veya risk altındaki görevleri öne çekerken zaten zamanında olan atamaları savurmaz—yeniden-atama cezası  $\rho_{r,\tau}$ 'yu tamamlayan bir churn freni.

**Amaç.**  $[0, T_{\max}]$  çalışma ufkunda sekiz metrik raporlanır: tamamlama oranı CR, makespan, ortalama görev gecikmesi, deadline ihlal oranı DVR, arıza toparlanma süresi, Jain iş yükü dengesi, yürütme kesintileri, görev yeniden-gönderim oranı ve karar gecikmesi. CR ve DVR birincildir; diğerleri takasları izler. Önemlisi, gecikme ve DVR yalnız tamamlanan görevler üzerinden değil *tüm* talep edilen görevler üzerinden hesaplanır (Bölüm IV-G):  $T_{\max}$ 'da bitmemiş bir görev, gecikme için ufukta sağdan-sansürlenir ve DVR için deadline-kaçırma sayılır. Bu survivorship-yanlılığından arınmış kural her yönteme aynen uygulanır; böylece bir politika, hizmet edemediği zor görevleri sessizce bırakarak gecikme veya DVR'ını düşüremez.

**Çevrim içi kurulum.** Görevler zamanla gelir, robotlar bilinmeyen anlarda arızalanabilir ve politika olay başına sert bir 50 ms bütçesi içinde  $x(t_k)$  üretmelidir.

## III. AHE-MRTA: EKOSİSTEM-GÜDÜMLÜ PARADIGMA SEÇİMİ

### A. Bağlam vektörü

Her tahsis olayında  $t_k$ , filonun ve açık görev kümesinin ortak durumunu 4-boyutlu bir bağlam vektörü  $c(t_k) \in [0, 1]^4$  içinde sıkıştırırız.  $n = |\mathcal{R}|$  filo boyutu,  $m = |\mathcal{T}(t_k)|$  açık görev sayısı,  $\mathcal{R}^{\text{av}}$  uygun robotlar (çalışır, sıkışmamış, kuyruk kapasiteli) ve  $\mathcal{R}^{\text{f}}$  arızalı veya navigasyonda sıkışmış robotlar olsun. Bileşenler:

$$c_1 = \min(1, m/n), \quad \text{görev yoğunluğu} \quad (2)$$

$$c_2 = |\mathcal{R}^{\text{av}}|/n, \quad \text{robot uygunluğu} \quad (3)$$

$$c_3 = |\{\tau : d_\tau - t_k \leq \Delta_d\}| / \max(1, m), \quad \text{deadline baskısı} \quad (4)$$

$$c_4 = |\mathcal{R}^{\text{f}}|/n, \quad \text{arıza oranı} \quad (5)$$

deadline ufku  $\Delta_d = 60$  s. Her boyut, farklı bir tahsis ailesinin sömürmek üzere kurulduğu bir sinyaldir:  $c_1, c_2$  yük-duyarlı tahsisin talep/arz dengesini [13];  $c_3$  deadline-kısıtlı tahsisin kullandığı zamansal boşluğu [14]; ve  $c_4$  hata-toleranslı tahsisin soğurması gereken bozulmayı [15] kodlar. Dördü de yayınlanan robot durum özetleri ve görev havuzundan çevrim içi hesaplanır; robotlar-arası iletişim gerektirmez.

TABLE I  
HER PARADIGMA İÇİN BAĞLAM PROTOTİP VEKTÖRLERİ  $V_i \in [0, 1]^4$ . SÜTUN BAŞLIKLARI:  $c_1$  GYD (GÖREV YOĞUNLUK),  $c_2$  RUY (ROBOT UYGUNLUK),  $c_3$  DL (DEADLINE),  $c_4$  ARZ (ARIZA).

| Hormon    | gyd | ruy | dl  | arz |
|-----------|-----|-----|-----|-----|
| H_SPATIAL | 0.7 | 0.7 | 0.1 | 0.1 |
| H_CRIT    | 0.3 | 0.5 | 0.8 | 0.2 |
| H_TEMP    | 0.5 | 0.5 | 0.9 | 0.1 |
| H_STAB    | 0.3 | 0.3 | 0.3 | 0.8 |
| H_RECOV   | 0.3 | 0.2 | 0.2 | 0.9 |

TABLE II  
İŞBİRLİĞİ MATRİSİ  $A$  VE BASKILAMA MATRİSİ  $S$ 'NİN SIFIR-DIŞI GİRDİLERİ.

| Matris          | Kaynak | Hedef     | Değer |
|-----------------|--------|-----------|-------|
| $A$ (işbirliği) | H_CRIT | H_TEMP    | 0.20  |
|                 | H_STAB | H_RECOV   | 0.20  |
| $S$ (baskılama) | H_TEMP | H_SPATIAL | 0.30  |

### B. Baskınlık dinamikleri

Baskınlık vektörü  $D(t) \in \mathbb{R}_{\geq 0}^5$  mevcut ekosistem durumunu kodlar. Her paradigma  $i$ 'nin sabit bir bağlam prototipi  $V_i \in [0, 1]^4$  vardır (Tablo I); uyumluluk skoru  $v_i(t_k) = \cos(V_i, c(t_k))$  paradigmanın güncel bağlamla ne kadar örtüştüğünü ölçer. İki seyrek matris yatay etkileşimleri yönetir: *işbirliği matrisi*  $A$  (2 sıfır-dışı giriş) ve *baskılama matrisi*  $S$  (1 sıfır-dışı giriş; Tablo II). Güncelleme şöyledir:

$$D(t_{k+1}) = \text{normalize} \left( \text{clip}_{[0,1]} \left( \alpha D(t_k) + \eta A D(t_k) - \lambda S D(t_k) + \beta \mathbf{p}(t_k) + \gamma \mathbf{v}(t_k) + \delta \mathbf{b}(t_k) \right) \right), \quad (6)$$

$\alpha=0.65$  (momentum),  $\eta=\lambda=0.12$  (işbirliği/baskılama),  $\beta=0.40$  (başarım),  $\gamma=0.20$  (uyumluluk),  $\delta=0.20$  (arıza kurtarma destek ağırlığı) ile. Burada  $\mathbf{p}(t_k)$  hormon başına başarım geri beslemesi ( $\text{CR}_k - \text{FR}_k$ )  $\cdot \mathbf{v}(t_k)$ ;  $\mathbf{v}(t_k)$  uyumluluk vektörü; ve  $\mathbf{b}(t_k)$  robot arızası algılandığında H\_RECOV ile H\_STAB'ı yükselten seyrek kurtarma destek vektörüdür. Normalize adımı  $\|D\|_1=1$  ve  $D \geq 0$ 'ı her döngüde güvenceye alır.  $\eta AD - \lambda SD$  terimleri Denklem (6)'i, çok-robotlu sistemler için etkili bir koordinasyon ilkeli olduğu gösterilen [16] Lotka–Volterra tipi bir kazanan-pekiştir / kazanan-baskıla rekabetine dönüştürür. Sabit bir düşük-seviye sezgisel portföyü üzerinde bir seçim kuralı olarak okunduğunda, güncelleme bir *hiper-sezgisel* oluşturur [17]: ekosistem atamayı kendisi çözmez, hangi klasik çözücünün — çevrim içi ve olay başına — çözeceğini seçer.

a) *Ağırlık üretimi.*: Baskınlık vektörü, sabit bir sezgisel-ağırlık matrisi  $M \in \mathbb{R}^{7 \times 5}$  ve düşük-sıcaklık softmax ile Eq. (1) maliyet ağırlıklarını belirler; baz ağırlık  $w_0$  ile harmanlanır:

$$w_{\text{eco}}(t_k) = \text{softmax}(MD(t_k), T_w), \quad w(t_k) = (1 - \beta_e) w_0 + \beta_e w_{\text{eco}}(t_k), \quad (7)$$

$T_w=0.3$ , harman  $\beta_e=0.7$ ; arıza altında ( $c_4>0$ ) harman bir toparlanma profiline  $w_r$  doğru  $\theta = \min(0.8, 0.5+0.6 c_4)$  ile kayar. Override tetiklenmediğinde Lotka–Volterra durumunun bir kararı etkilediği *tek* kanal budur.

b) *Maliyet şekillendirme.*: İki doğrusal-olmayan terim Eq. (1)'u deadline için keskinleştirir. *Sert fizibilite kapısı*: öngörülen varış  $a_{r,\tau}$  deadline'ı adaptif slack  $\Delta_s$  ötesinde aşarsa çift reddedilir,  $a_{r,\tau} > d_\tau + \Delta_s \Rightarrow C_{r,\tau}=\infty$ . *Aciliyet yükseltmesi*: bir görev deadline bütçesinin  $u_0=0.7$  kesrini geçince zamansal terim şişer,  $\hat{u}_\tau = u_\tau(1 + \zeta e^2)$ ,  $e = (u_\tau - u_0)/(1 - u_0)$ ; böylece risk altındaki *atanmamış* görevler öne çekilir, zamanında incumbent'lar muafır (churn freni).

### C. Dağıtım

Dağıtıcı önce iki sert bağlam geçersiz kılmasını denetler (arıza oranı  $> 0.05$  ise H\_RECOV zorlanır; deadline baskısı  $> 0.5$  ise H\_TEMP zorlanır); hiçbirini tetiklemezse paradigma  $p^*(t_k) = \arg \max_i D_i(t_k)$  ile seçilir (Tablo III). H\_TEMP paradigması, baskınlık bilgilendirici olmadığında (entropi maksimuma yakın) varsayılan geri dönüştür.

a) *İş-koruma (work-conservation).*: Tüm paradigmlar boyunca yol gösterici bir ilke, uygun iş kaldığı sürece filo kapasitesinin asla atıl bırakılmamasıdır. Her olayda her uygun robota aktif paradigmanın LSA'sıyla (Denk. (8)) en iyi uygun görev atanır ve toparlanma paradigması (*orphan\_first*) bir robot arızası veya navigasyon iptali ile yetim kalan görevleri yeniden gönderir; böylece bir bozulma kalıcı kayıp yerine en fazla bir yeniden-denemeye mal olur. Bu, atamaları donduran ve dolayısıyla arızalı robotun görevlerini kurtarmayan—koşu sonuna dek atıl kapasite bırakan—commit-once




Fig. 1. Ekosistem-Güdümlü Paradigma Seçimi mekanizması. Her tahsis olayında bağlam vektörü  $c(t)$ , sabit işbirliği/baskılama matrisleri  $A, S$  üzerinden baskınlık güncellemesini (Denk. 6) sürür; baskın hormon  $p^* = \arg \max_i D_i$  beş tahsis paradigmasından birini seçer ve AHE tahsisçisi bunu çalıştırarak robot başına görev kuyruklarını yayımlar.

TABLE III  
BEŞ HORMON, BEŞ TAHSİS PARADIGMASI.

| Hormon    | Paradigma      | İç mekanizma                     |
|-----------|----------------|----------------------------------|
| H_SPATIAL | spatial_greedy | en-yakın-uygun + reddet          |
| H_CRIT    | priority_first | öncelik-katmanlı LSA             |
| H_TEMP    | edf_strict     | EDF bipartit (çok-fazlı)         |
| H_STAB    | commit_once    | sert yapışkan, yeniden-atama yok |
| H_RECOV   | orphan_first   | yetim kurtarma + bipartit        |

tahsisin yapısal karşıtıdır. Bölüm V'in gösterdiği gibi, bu iş-koruyan toparlanma AHE-MRTA'nın dayanıklılık marjının mekanizmasıdır: commit-once temel yöntem, başarısız işi yeniden denemediği için karışık strese tam 24.3 pp tahsis uygunluğu kaybeder. Tek indirgenemez atıl süre, tekrarlı navigasyon arızasından sonra hiçbir görevin anlık denenebilir olmadığı backoff'tur.

#### D. Paradigma kütüphanesi

Beş paradigma tek bir ilkel paylaşıyor ve yalnızca onun girdilerini nasıl şekillendirdiklerinde ayrışır. Uygunluk-maskelenmiş bir maliyet matrisi  $C^{(p)}$  verildiğinde, her paradigma  $p$  bir doğrusal toplam atama (LSA) çözer:

$$x^{(p)} = \arg \min_{x \in \mathcal{X}} \sum_{r \in \mathcal{R}} \sum_{\tau \in \mathcal{T}(t_k)} C_{r,\tau}^{(p)} x_{r,\tau}, \quad (8)$$

burada  $\mathcal{X}$  robot başına kuyruk kapasitesi  $\sum_{\tau} x_{r,\tau} \leq Q$ , tek-atama kısıtı  $\sum_r x_{r,\tau} \leq 1$  ve yetenek uygunluğunu zorlar; uygun olmayan çiftler  $C_{r,\tau}^{(p)} = \infty$  ile maskelenir.  $C_{r,\tau}$  Denklem (1) taban maliyetini göstermek üzere, paradigmalar  $C^{(p)}$ 'yi ve kuyruk sıralamasını şöyle örnekler.

- spatial\_greedy* (H\_SPATIAL):  $C_{r,\tau}^{(p)} = T_{r,\tau}$ , yalnız seyahat süresi, en yakın uygun robota açgözlü atanır — metrik MRTA'nın mesafe-azaltan kuralı [13], [18].
- priority\_first* (H\_CRIT): görevler kritiklik katmanlarına  $\pi_r=3>2>1$  bölünür ve Denklem (8) katman katman çözülür; böylece kritik görevler robotları önce kapar — katmanlı açık artırma/uzlaşa atamasında olduğu gibi [19], [20].
- edf\_strict* (H\_TEMP, varsayılan): görevler en erken deadline  $d_r$ 'ya göre sıralanır ve sert bir uygunluk kapısı altında eklenir (varış  $> d_r \Rightarrow C^{(p)} = \infty$ ); bu, deadline-kısıtlı tahsis için en-erken-deadline-önce çizelgelemenin bipartit

---

**Algorithm 1** AHE-MRTA Olay Çevrimi
 

---

**Require:** robotlar  $\mathcal{R}$ , açık görevler  $\mathcal{T}(t_k)$ , durum  $D(t_k)$ , sabit  $A, S, V$ , hiperparametreler  $\alpha, \eta, \lambda, \beta, \gamma, \delta$   
 1:  $c \leftarrow \text{BAĞLAMVEKTÖRÜ}(\mathcal{R}, \mathcal{T}(t_k))$  {4 sinyal,  $c_1-c_4$ }  
 2:  $\mathbf{v} \leftarrow (\cos(V_i, c))_{i=1}^5$ ;  $\mathbf{p} \leftarrow (\text{CR}_k - \text{FR}_k) \cdot \mathbf{v}$ ;  $\mathbf{b} \leftarrow \text{ARIZADESTEK}(\mathcal{R})$   
 3:  $D \leftarrow \text{normalize}(\text{clip}_{[0,1]}(\alpha D + \eta AD - \lambda SD + \beta \mathbf{p} + \gamma \mathbf{v} + \delta \mathbf{b}))$   
 4:  $p^* \leftarrow \text{BAĞLAMGEÇERSİZKIL}(c)$  **tetiklendiyse, değilse**  $\arg \max_i D_i$   
 5:  $x \leftarrow \text{PARADIGMA}_{p^*}(\mathcal{R}, \mathcal{T}(t_k))$  {Tablo III}  
 6: **yayınla**  $x$ 'ten robot başına görev kuyrukları  
 7: **döndür**  $D, x$

---

gerçeklemesidir [14], [21]. Elde edilen robot-başı yürütme sırası, ardından deadline-feasible bir en-ucuz-ekleme geçişiyle rafine edilir; bu geçiş yalnız EDF sırasına göre hiçbir deadline kaçırmayı eklemekten seyahati kısalttığına kabul edilir—EDF uygunluk garantisini koruyarak hareket maliyetini düşürür.

- *commit\_once* (H\_STAB): mevcut atamalar dondurulur ( $r$ 'nin kuyruğundaki bir görev yenilmez bir yapışkanlık bonusu korur), kendinden-uyarlamalı taahhüt-bir-kez evriminde olduğu gibi yeniden-atama çalkantısını yok eder [12].
- *orphan\_first* (H\_RECOV): arızalı veya sıkışmış bir robot tarafından terk edilen görevler, diğer hepsinden önce ayrı bir kurtarma geçişinde atanır — dayanıklı MRTA'nın kurtarma-öncelikli kuralı [15], [18].

Paradigmalar bağımsızdır (geçişler arası paylaşılan durum yok); tek kalıcı durum  $D(t)$ 'dir. Denklem (8)'daki LSA ilkeli en kötü durumda  $\max(n, m)$ 'de küptür, ancak değerlendirilen ölçeklerde her olay milisaniye-altı duvar-saati süresinde çözülür (Bölüm VI); dolayısıyla paradigma seçimi gerçek-zaman bütçesini etkilemez.

### E. Algoritma

### F. Konfigürasyon

Hormon-paradigma eşlemesi (Tablo III),  $A/S$  matrisleri (Tablo II), bağlam prototipi  $V$  ve tüm skaler hiperparametreler ( $\alpha=0.65$ ,  $\eta=\lambda=0.12$ ,  $\beta=0.40$ ,  $\gamma=0.20$ ,  $\delta=0.20$ , softmax sıcaklığı  $T=0.3$ ) bir kez belirlenir ve tüm senaryo ve ölçeklerde sabit tutulur. Senaryo başına ayar, öğrenme veya uyarlanır parametre çizelgesi yoktur. Skaler ağırlıklar metrik bazında aranmadı, yuvarlak ve yorumlanabilir değerlerde sabitlendi; belirlenimci override'lar akut rejimlere hâkim olduğundan tahsis sonuçları bu değerlere karşı duyarsızdır (tek-adım  $\pm$  değişim, raporlanan tüm fitness farklarını bir standart sapma içinde bırakır) — bu, ayarlanmış bir uyum değil, dayanıklılık özelliğidir.

## IV. DENEY TASARIMI

### A. Donanım Platformu

Tüm deneyler Intel Core i7-11800H iş istasyonunda çalıştırıldı (8 fiziksel çekirdek / 16 iş parçacığı, 2.30 GHz temel saat, 16 GiB DDR4 RAM, Ubuntu 24.04 LTS, Linux 6.17). Makinede NVIDIA RTX 3050 Mobile GPU bulunmakta, ancak tescilli sürücüsü yüklü değildir; Gazebo ve RViz tüm görselleştirmeyi Mesa llvmpipe yazılım rasterleştirmesiyle (`LIBGL_ALWAYS_SOFTWARE=1`, `GALLIUM_DRIVER=llvmpipe`) yapar. GPU ivmesi hiçbir noktada kullanılmaz: karşılaştırma tamamen CPU sınırlıdır ve Mesa destekli herhangi bir x86-64 makinede yeniden üretilebilir.

### B. Yazılım Yığını

**Gazebo Harmonic** (gz-sim 8.x) [22], **ROS 2 Jazzy** (Ara. 2024) [23] ve **Nav2** [24] kullanıldı. Robotlar **TurtleBot3 Waffle Pi** [25] modelidir; her biri 360-ışınlı 2-B lidar (5 Hz, 8 m menzil) ve IMU (200 Hz) taşır ve diferansiyel-tahrik denetleyicisiyle sürülür ( $v_{\max}=0.26$  m/s,  $\omega_{\max}=1.82$  rad/s).

Her robot kendi ROS 2 ad uzayında tamamen bağımsız bir Nav2 yaşam döngüsü çalıştırır: 0.40 m şişirme yarıçaplı küresel/yerel costmap, Regulated Pure-Pursuit denetleyici ve davranış ağacı gezgini. Yerelleştirme *ground-truth* olarak sağlanır — her robotun başlangıç pozuna sabitlenmiş statik bir `map`→`odom` dönüşümü — böylece kıyaslama tahsis kalitesini yerelleştirme hatasından yalıtır (kasıtlı bir deneysel kontrol; Bölüm VII-F). `ros_gz_bridge` robot başına `/scan`, `/odom`, `/cmd_vel`, `/joint_states` ve TF aktarır; bir TF-aktarıcı düğüm robot başına ad uzayındaki TF ağaçlarını küresel çerçevede birleştirir. Tüm Nav2 parametreleri yöntemler arasında özdeştir.

### C. Denetim Arenası

Arena, 20×20 m'lik duvarlı kapalı bir maket. İki yatay bölücü duvar 1.5 m genişliğinde orta bir geçitle alanı üst şerit, orta geçit ve alt şerit olarak böler. Yan duvarlar boyunca iki sıra kare sütun (0.5×0.5 m) ve şeritlerde dört silindirik engel ( $r=0.35$  m) yer alır. 42 aday denetim ara noktasından oluşan özgünlük doğrulanmış bir ızgara (engel-farkında, noktalar arası min. mesafe > 1 m) tanımlıdır; her koşu tohuma göre deterministik biçimde örnekler. Şekil IV-C, arena düzenini ölçeğe bağlı başlangıç konumları ve örneklenmiş görev kümeleriyle birlikte gösterir.




Fig. 2. Sistem mimarisi. Ekosistem yöneticisi hormon durum vektörünü korur, baskınlık dinamiklerini evirir, aktif paradigmayı seçer ve ROS 2 konuları üzerinden robot başına optimize görev kuyruklarını yayımlar. Her robot bağımsız bir Nav2 yaşam döngüsü çalıştırır ve görev yürütme geri bildirimini (tamamlama, arıza, gecikme) bağlam döngüsünü kapatmak için ekosistem yöneticisine iletir.

AHE-MRTA — Ortam senaryo haritaları (robot  $\times$  görev ölçekleri)




Fig. 3. Ölçeğe bağlı arena konfigürasyonları. **Sol**: 3r/15g – robotlar merkezi sütun; orta yoğunluk. **Orta**: 5r/25g – iki başlangıç sütunu; orantılı artış. **Sağ**: 10r/50g – beş sütunun tamamı; yüksek yoğunluk. Mavi yıldız: görev hedefleri (tohum 1); renkli üçgen: robot başlangıç konumları. Tüm noktalar engel-serbest.

#### D. Değerlendirme Ölçekleri

Üç Gazebo ölçeği değerlendirilir (Tablo IV), her biri 60 deney (4 yöntem  $\times$  3 senaryo  $\times$  5 tohum):

$N > 3$ 'te Nav2 yaşam-döngüsü yarış koşulları (`odom`  $\rightarrow$  `base_link` dönüşümünün costmap etkinleşmesinden sonra gelmesi), 3r/5r'de  $i$ . robot için 6s, 10r'de 20s yaşam-döngüsü-yöneticisi aktivasyonunu öteleyerek ve düğüm başlangıcında kimlik-dönüşüm yayını ekleyerek çözüldü. Üç ölçeğin tamamı aynı arena, engel haritası ve Nav2 parametrelerini kullanır.

#### E. Stres Senaryoları

Üç senaryo farklı tahsis yönlerini zorlar:

- **robot\_failure**: rastgele seçilen bir robot  $t = 0.3 \cdot T_{\max}$ 'da kesin olarak arızalanır (3r'de:  $t \approx 165$  s). Atanan görevleri sahipsiz kalır ve yeniden dağıtılması gerekir. Reaktif toparlanmayı ve paradigma yükseltmeyi (orphan-rescue paradigması) sınar.



TABLE IV  
GAZEBO DEĞERLENDİRME ÖLÇEKLERİ

| Ölçek                       | Robot | Görev | Yoğunluk | Toplam deney |
|-----------------------------|-------|-------|----------|--------------|
| 3r-az                       | 3     | 9     | 3.0 g/r  | 60           |
| 3r-orta                     | 3     | 15    | 5.0 g/r  | 60           |
| 3r-yüksek                   | 3     | 24    | 8.0 g/r  | 60           |
| 5r-orta                     | 5     | 25    | 5.0 g/r  | 60           |
| 10r-orta                    | 10    | 50    | 5.0 g/r  | 60           |
| <b>Toplam Gazebo deneyi</b> |       |       |          | <b>300</b>   |

- **mixed\_stress:** görevler heterojen önceliklere sahiptir (düşük/orta/yüksek, oran 1:2:2) ve bir robot  $t = 0.2 \cdot T_{\max}$ 'da arızalanır. Öncelik ve arıza boyutlarında eş zamanlı rejim uyumunu sınar.
- **deadline\_pressure:** her görev sıkı bir son tarih paylaşır  $d_\tau = t_{\text{spawn}} + 90$  s ( $v_{\max}$ 'da en uzak ara noktaya Nav2 seyahat süresinin yaklaşık  $1.3 \times$ 'i). EDF sıralama ve aciliyet güdümlü çift-terafı dağıtımı sınar.

#### F. Kıyaslama Yöntemleri

Her baskın çevrim içi MRTA gözücü ailesinden bir temsilci ile karşılaştırıyoruz; birlikte, AHE-MRTA'nın üzerinde geçiş yaptığı tasarım uzayını kapsarlar. Tüm temel yöntemler özgün makalelerinden çerçevemiz içinde yeniden uygulanmıştır ve özdeş bir olay döngüsü, ROS 2 konu arayüzü, maliyet girdileri (seyahat süresi, aciliyet, öncelik, enerji), robot başına kuyruk sınırı  $Q$  ve Nav2 istemcisi paylaşır; *yalnızca tahsis politikası farklıdır*. Parametreler özgün makalelerde belirtildiği yerde onları izler ve tüm senaryo/ölçeklerde sabit tutulur.

a) *BiG-MRTA* [9] (*bipartit eşleme*): Sabit çok-kriterli kenar maliyetiyle bir robot-görev bipartit grafiği kurar ve her olayda maksimum-ağırlıklı eşleme çözer; atamalar *tek seferde commit edilir* ve asla yeniden ele alınmaz. Belirlenimci, en-düşük-gecikmeli tek-paradigma gözücü olarak dahil edildi. Commit-once politikası AHE'nin geçiş yaklaşımının doğrudan antitezidir: sıfır yeniden planlama maliyeti öder ancak atanmış robotu arızalanan veya deadline boşluğu tükenen görevleri terk eder.

b) *RoSTAM-EA* [12] (*evrimsel*): Aday atama vektörlerinden oluşan bir popülasyonu turnuva seçimi, çaprazlama ve mutasyonla her tahsis olayında evirir; elit birey gönderilir. Öz-uyumlu stokastik-arama ailesinin temsilcisi olarak dahil edildi. Tek-atışlık eşlemeden daha zengin bir atama uzayını keşfeder ancak iki-üç merteye daha yüksek karar gecikmesiyle; ayrıca yeniden eniyilemesi bağlamın *neden* değiştiğine kördür.

c) *Consensus-DBTA* [11] (*uzlaşma demeti*): Robotlar görev demetlerine yinelenmeli teklif verir ve çatışmaları bir uzlaşma aşamasıyla çözer; son derece kararlı atamalar üretir (tahsis kararsızlığı  $\approx 0$ ). Dağıtık açık-artırma/uzlaşma ailesinin temsilcisi ve en güçlü tamamlama-oranı temel yöntemi olarak dahil edildi. Kararlılığı aynı zamanda zayıflığıdır: rejim kaymaları (arızalar, deadline tırmanması) yeniden-teklif turları boyunca yavaş yayılır.

Ablasyon varyantı (örn. geçişsiz tek-paradigmalı AHE) dahil edilmedi; beş paradigmanın kendisi klasik ilkeler olduğundan, tek-paradigma davranışı karşılık gelen temel yöntem ailesiyle yaklaşıklanır (Tablo III).

#### G. Metrikler

Sekiz metrik raporlanır: tamamlama oranı (CR), son tarih ihlal oranı (DVR), yapım süresi, ortalama görev gecikmesi, iş yükü dengesi (Jain), tahsis kararsızlığı (yeniden atama sayısı), karar gecikmesi ve mesaj sayısı. CR ve DVR birincil metriklerdir; yapım süresi ve kararsızlık ikincildir (Nav2 yeniden planlama maliyetiyle karışmış).

a) *Survivorship-yanlılığından arınmış gecikme ve DVR*: Gecikme ve DVR'ı yalnız *tamamlanan* görev alt-kümesi üzerinden raporlamak, bir politikayı iş bırakmak için ödüllendirir: bir yöntemin düşürdüğü zor görevler—tipik olarak uzak, geç veya çekişmeli olanlar—paydasına hiç girmez, dolayısıyla ortalama gecikmesi ve ihlal oranı daha kolay, kendi seçtiği bir örneklem üzerinden hesaplanır. Bu yanlılığı, gecikme ve DVR'ı *tüm* talep edilen görevler üzerinden puanlayarak gideririz.  $\mathcal{T}$  talep kümesi,  $t_\tau^a$  aktivasyon ve  $t_\tau^c$  tamamlama zamanı,  $T_{\max}$  çalışma ufku olsun. Görev başına gecikme, bitmemiş görevler için ufukta sağdan-sansürlenir,

$$\delta_\tau = \begin{cases} t_\tau^c - t_\tau^a, & \tau \text{ tamamlandı,} \\ T_{\max} - t_\tau^a, & \tau \text{ bitmedi,} \end{cases} \quad \bar{\delta} = \frac{1}{|\mathcal{T}|} \sum_{\tau \in \mathcal{T}} \delta_\tau, \quad (9)$$

ve deadline'lı bir görev, geç tamamlanırsa *veya* hiç tamamlanmazsa ihlal sayılır,

$$\text{DVR} = \frac{|\{\tau : d_\tau < \infty \wedge (t_\tau^c > d_\tau \vee \tau \text{ bitmedi})\}|}{|\{\tau : d_\tau < \infty\}|}. \quad (10)$$

TABLE V  
TAHSIS UYGUNLUĞU (NAV2-BAĞIMSIZ, 100 TOHUM, 5 ROBOT / 25 GÖREV, BİRİNCİL ÖLÇEK). YÜKSEK DAHA İYİDİR. SENARYO BAŞINA BİRİNCİ SIRA **kalın**.

| Yöntem           | Robot ar.    | Karma str.   | Deadline     |
|------------------|--------------|--------------|--------------|
| <b>AHE-MRTA*</b> | 0.538        | 0.538        | <b>0.483</b> |
| BiG-MRTA         | 0.501        | 0.303        | 0.480        |
| RoSTAM-EA        | 0.441        | 0.441        | 0.459        |
| Consensus-DBTA   | <b>0.540</b> | <b>0.539</b> | 0.476        |

Kural her yönteme ve her ölçekte aynen uygulanır. Şeffaflık için geleneksel yalnız-tamamlanan gecikme ve DVR de kaydedilir; bir yöntem görev kümesinin tamamını tamamladığında (CR=1) ikisi tam çakışır ve yalnız bir yöntemin hizmet etmeden bıraktığı görevler ölçüsünde ayrışır.

#### H. İstatistiksel Analiz

Her senaryo ailesi içinde Bonferroni düzeltmesi uygulanan ikili çift-yönlü Mann–Whitney U testleri (senaryo başına 3 temel yöntem  $\times$  7 metrik = 21 test). 5-robot birincil ölçekte her hücrede  $n=5$  koşu vardır (tek yoğunluk, 25 görev); 3-robot ölçeği üç yoğunluk havuzlar ( $n=15$ ) ve 10-robot ölçeği  $n=5$ 'tir. Küçük hücrelere dayanıklı etki-büyüklüğü kestirimi olarak ek biçimde Cliff  $\delta$  raporlanır. 100-tohumlu Nav2-bağımsız simülatör birincil hipotez testi olarak kullanılır; Gazebo sonuçları gerçekçi yürütme gürültüsü altında doğrulama görevi görür.

#### V. TAHSIS-UYGUNLUK SONUÇLARI (NAV2-BAĞIMSIZ)

Tahsis ve toparlanma kalitesini Nav2'nin yerel planlayıcısı, costmap yeniden inşaları ve fiziksel hareketin getirdiği geometri-bağımlı seyahat varyansından yalıtım için, navigasyon *maliyetini* robot-görev grafiğinde sabit-sürelili bir kenar olarak soyutlarken navigasyon *sonuçlarını* stokastik tutan (bir hedef, konuma-bağlı bir olasılıkla başarısız olabilir ve yeniden denenmelidir) Nav2-bağımsız bir simülatör kurduk. Uygunluk, deadline'larından önce tamamlanan görevlerin öncelik-ağırlıklı oranıdır; başarısız hedefler toparlanmayı gerektirdiğinden, metrik yalnız atama kalitesini değil navigasyon arızasına dayanıklılığı da ödüllendirir. Senaryo başına 100 tohumla AHE-MRTA ve Consensus-DBTA istatistiksel eş-liderdir: AHE *deadline\_pressure*'da birinci, *robot\_failure*'da eşit ve *mixed\_stress*'te 0.001 geride — tüm farklar bir std sapmanın ( $\approx 0.10$ ) çok içinde:

AHE-MRTA ve Consensus-DBTA üç senaryoda da istatistiksel olarak ayırt edilemez eş-liderlerdir: AHE *deadline\_pressure*'da dar farkla önde (0.483 vs Cons-DBTA 0.476 ve BiG 0.480), *robot\_failure*'da neredeyse eşit (AHE 0.538, Cons-DBTA 0.540) ve *mixed\_stress*'te Cons-DBTA 0.001 önde (0.539 vs 0.538) — tüm farklar bir std sapmanın ( $\approx 0.10$ ) çok içinde. İki eş-lider ortak bir mekanizmayı paylaşır: ikisi de navigasyon hedefi başarısız olan görevleri ve arızalı robotların yetim bıraktığı görevleri yeniden gönderir, böylece stokastik bir arıza en fazla bir yeniden-denemeye mal olur, kayıp göreve değil. Commit-once BiG-MRTA atamaları sabitler ve hiç yeniden yönlendirmez, bu yüzden bu görevleri toparlayamaz ve *mixed\_stress*'te +23.5 pp (0.303), *robot\_failure*'da +3.9 pp (0.501) geride kalır; bu açık *toparlanma dayanıklılığıdır*, atama kalitesi değil. *deadline\_pressure*'da toparlanabilen üç yöntem 0.7 pp'lik bir bant içindedir: deadline'lar sıkıştığında geç yeniden-denemeler zamanında-kredi kazanmaz, dolayısıyla toparlanma avantajı sıkışır (Bölüm VII-C). Fiziksel Nav2 yığımında aynı dayanıklılık, BiG-MRTA'ya karşı en yüksek tamamlama oranı olarak yeniden belirir (+25.4 pp, Bölüm VI). Şekil 4 özetler:

#### A. Ölçeklenebilirlik

Ölçeklenebilirlik iki tamamlayıcı yolla kurulur. Navigasyon-bağımsız düzlemde idealize varış modeli robot sayılarını yüksek istatistiksel güçle ucuza taramamızı sağlar. Dört yöntemi  $N \in \{3, 5, 10\}$  robotta, robot başına sabit beş görev yoğunluğuyla ( $M = 5N$ ), hücre başına 100 tohum ve üç senaryoda (3.600 koşu) çalıştırırız. Fiziksel Gazebo doğrulaması 3r, 5r ve 10r ölçeklerinde gerçekleştirilir. Tablo VI ve Şekil 5 senaryolar üzerinden ortalananmış sonuçları raporlar.

AHE-MRTA her ölçekte en yüksek uygunluğu korur.  $N = 3$ 'te Cons-DBTA'nın hafifçe önündedir (0.488 vs 0.483);  $N = 5$ 'te Cons-DBTA'ya +0.1 pp, BiG'e +9.2 pp öne geçer. Karar gecikmesi on robotta  $\approx 0.10$  ms'de kalır — 5s yeniden planlama periyodunun dört mertebeden fazla altında ve evrimsel RoSTAM-EA temel yönteminden ( $N = 10$ 'da 6.5 ms)  $\approx 60\times$  daha hızlı. 5- ve 10-robot ölçeklerindeki fiziksel Gazebo doğrulaması (her biri 60 deney) bu simülatör eğilimlerini tam Nav2 yığımında onaylar; senaryo bazlı sonuçlar 3-robot kıyaslamasıyla birlikte Bölüm VI'da raporlanır.

#### VI. GAZEBO KIYASLAMA SONUÇLARI

Tam fiziksel-yığın Gazebo kıyaslamasını raporluyoruz. Her yöntem özdeş Nav2 parametreleri, dünya ve zamanlama bütçeleriyle çalışır; yalnızca tahsis politikası farklıdır. Üç yoğunluk düzeyi (9/15/24 görev)  $\times$  5 tohum = 180 3r






Fig. 4. Nav2-bağımsız tahsis uygunluğu (ortalama  $\pm$  std), hücre başına 100 tohum, 5 robot / 25 görev (birincil ölçek). AHE-MRTA ve Consensus-DBTA istatistiksel eş-liderdir: AHE deadline\_pressure'da önde, robot\_failure'da eşit ve mixed\_stress'te 0.001 geride — tüm farklar bir std sapmanın ( $\approx 0.10$ ) içinde.

TABLE VI

ÖLÇEKLENEBİLİRLİK (NAV2-BAĞIMSIZ, 100 TOHUM, SABİT YOĞUNLUK 5 GÖREV/ROBOT, ÜÇ SENARYO ORTALAMASI). UYGUNLUK  $\uparrow$ , GECİKME (MS)  $\downarrow$ . ÖLÇEK BAŞINA EN İYİ **kalm**.

| Yöntem           | 3 robot      |             | 5 robot      |             | 10 robot     |             |
|------------------|--------------|-------------|--------------|-------------|--------------|-------------|
|                  | Uyg.         | Gec.        | Uyg.         | Gec.        | Uyg.         | Gec.        |
| <b>AHE-MRTA*</b> | <b>0.488</b> | 0.04        | <b>0.520</b> | 0.05        | <b>0.493</b> | 0.11        |
| BiG-MRTA         | 0.407        | 0.02        | 0.428        | 0.04        | 0.445        | 0.10        |
| RoSTAM-EA        | 0.405        | 1.94        | 0.449        | 3.37        | 0.439        | 6.57        |
| Consensus-DBTA   | 0.483        | <b>0.01</b> | 0.519        | <b>0.02</b> | 0.488        | <b>0.04</b> |

deneyi; 5r ve 10r her biri 60 deney ekler (300 toplam). Bonferroni düzeltmeli Mann–Whitney U tüm karşılaştırmalarda uygulanır.

Şekil 6, dört yöntemin aynı *mixed\_stress* örneğinde (5 robot / 25 görev, tohum 1) yürüttüğü gerçek robot yörüngelerini gösterir. Yörüngeler kaydedilen ground-truth pozlarından yeniden oluşturulur ve arena işgal haritasına örneklenmiş denetim noktalarıyla birlikte bindirilir; her politikanın filoyu nasıl dağıttığını ortaya koyar (AHE-MRTA ve Consensus-DBTA tüm noktaları kapsamak için robotları yayar, commit-once BiG-MRTA arenanın daha çoğunu kapsamamasız bırakır).

Şekil 7 bu durağan-harita görünümünü, en büyük 10-robot yapılandırmasının AHE-MRTA altında bir *dynamic\_task\_arrival* örneğinde koşma anında alınmış canlı bir anlık görüntüsüyle tamamlar. Gazebo Harmonic fiziksel görünümü on Turtle-Bot3 robotun tümünün arenaya, atanmış denetim noktalarına doğru dağıldığını gösterir; eşzamanlı RViz görünümü ise paylaşılan işgal haritasını her robotun güncel Nav2 küresel planı (robot başına bir renk) ve ground-truth pozuyla bindirir. İki panel aynı arena geometrisini paylaşır ve olay-başına, iş-koruyan dağıtımı doğrudan görünür kılar: herhangi bir anda filo tek bir koridorda kuyruğa girmek yerine her iki şeride yayılmıştır; ekosistem yeni görevler geldikçe filo kapasitesini böyle meşgul tutar.

a) *AHE nerede kazanır.*: 5-robot birincil ölçekte AHE-MRTA her senaryoda tam tamamlamaya ulaşır ( $CR = 1.000$ ), görev-terk-eden BiG-MRTA ise *deadline\_pressure*'da 0.736'ya, *mixed\_stress*'te 0.728'e düşer. Zamanında-etkin tamamlamada ( $CR \times (1 - DVR)$ ) AHE-MRTA *robot\_failure*'da (0.99; temel yöntemler 0.88–0.93) ve *mixed\_stress*'te (0.72; diğerleri  $\leq 0.67$ ) öne geçer; *deadline\_pressure*'da üç toparlanma-yetenekli yöntem istatistiksel olarak berabere (AHE 0.64, Cons-DBTA 0.68, RoSTAM-EA 0.60, hepsi  $CR = 1.000$ ), tahsis-uygunluk karşılaştırmasındaki eş-liderlikle uyumlu. AHE'nin paradigma seçimi yetim-kurtarma ve EDF-bipartit ilkelerini devreye sokar; avantaj en belirgin *robot\_failure*'da görülür: AHE her iki ölçekte tamamlamada öne geçer (5 robotta  $CR = 1.000$ , 10 robotta 0.996) ve ihlal oranı sıfıra yakındır (5 robotta  $DVR = 0.008$ ; aşağıya bakınız).

b) *AHE nerede maliyet getirir.*: Aynı agresiflik, Nav2 hareketiyle karışan fiziksel maliyet metriklerini ölçülü biçimde yükseltir (Bölüm VII) ve — hücre başına  $n=5$  ile — düzeltmeden sağ çıkmaz. *robot\_failure*'da AHE'nin ortalama görev gecikmesi (101 s) toparlanma-yetenekli yöntemler arasında en yüksektir (diğerleri 75–89 s) ve arıza-toparlanma süresi (73 s) orta sıradadır: Cons-DBTA (103 s) ve RoSTAM-EA (87 s)'den hızlı, commit-once BiG-MRTA (64 s)'den yavaş. *mixed\_stress* ve *deadline\_pressure*'da görev-terk-eden BiG-MRTA en büyük gecikmeleri (253–260 s) gösterir, çünkü tamamladığı az sayıda görev çok geç biter — bu yüzden o karşılaştırma birebir değildir. Ancak düzeltilmiş yeniden-




Fig. 5. Robot sayısına karşı ölçeklenebilirlik (Nav2-bağımsız SIM, 100 tohum, üç senaryo ortalaması): (a) uygunluk, (b) tamamlama oranı, (c) toparlanma süresi, (d) karar gecikmesi. AHE-MRTA tüm ölçeklerde uygunluk ve tamamlamada öndedir, milisaniye-altı gecikmeyle.

TABLE VII

MAIN COMPARISON AT THE PRIMARY 5-ROBOT / 25-TASK SCALE;  $n=5$  RUNS (SEEDS) PER CELL. SIGNIFICANCE VS AHE-MRTA\*: \* $p<0.05$ , \*\* $p<0.01$ , \*\*\* $p<0.001$  (MANN-WHITNEY U, BONFERRONI-CORRECTED WITHIN EACH SCENARIO FAMILY OF 21 TESTS).

| Method                         | CR↑                  | Delay↓(s)          | RecT↓(s)           | Preempt↓    | Churn↓               |
|--------------------------------|----------------------|--------------------|--------------------|-------------|----------------------|
| <i>Scenario: robot_failure</i> |                      |                    |                    |             |                      |
| <b>AHE-MRTA*</b>               | <b>1.000 ± 0.000</b> | 101.2 ± 12.5       | 73.3 ± 14.2        | 0.00 ± 0.00 | <b>0.024 ± 0.022</b> |
| BiG-MRTA                       | 0.960 ± 0.049        | 89.3 ± 39.8        | <b>63.6 ± 19.1</b> | 0.00 ± 0.00 | <b>0.024 ± 0.036</b> |
| RoSTAM-EA                      | <b>1.000 ± 0.000</b> | 88.5 ± 6.9         | 87.5 ± 22.7        | 0.00 ± 0.00 | 0.088 ± 0.052        |
| Cons-DBTA                      | <b>1.000 ± 0.000</b> | <b>75.2 ± 13.7</b> | 102.9 ± 41.6       | 0.00 ± 0.00 | 0.064 ± 0.036        |
| <i>Scenario: mixed_stress</i>  |                      |                    |                    |             |                      |
| <b>AHE-MRTA*</b>               | <b>1.000 ± 0.000</b> | 51.7 ± 4.3         | 35.4 ± 19.2        | 0.00 ± 0.00 | <b>0.016 ± 0.022</b> |
| BiG-MRTA                       | 0.728 ± 0.066        | 252.7 ± 50.2       | 29.3 ± 20.0        | 0.00 ± 0.00 | 0.032 ± 0.030        |
| RoSTAM-EA                      | <b>1.000 ± 0.000</b> | <b>50.7 ± 8.8</b>  | <b>27.7 ± 15.7</b> | 0.00 ± 0.00 | 0.096 ± 0.046        |
| Cons-DBTA                      | <b>1.000 ± 0.000</b> | 60.4 ± 10.2        | 58.8 ± 40.9        | 0.00 ± 0.00 | 0.096 ± 0.046        |

gönderim churn metriğinde AHE en iyi bantta kalır (görev başına  $\leq 0.05$  yeniden-gönderim, sıfır yürütme kesintisi), commit-once temel yöntemleriyle eşit veya daha iyi: ham sayaçların bildirdiği görünürdeki “kararsızlık” açığı, fiziksel yeniden-atama yerine allocator *çağrı kadansını* ölçmenin bir artefaktıydı (Bölüm VII). Gecikme takasını Bölüm VII’de nicelliyoruz.

c) *Verimlilik*.: Tablo IX ikincil verimlilik metriklerini raporlar. AHE-MRTA’nın karar gecikmesi tüm senaryolarda milisaniye-altı kalır (0.18–0.23 ms), bipartit BiG-MRTA (0.08–0.12 ms) ile aynı mertebeye ve evrimsel RoSTAM-EA’dan (26–42 ms) iki mertebeden fazla hızlı. Uzlaşma temel yöntemleri tek seferde commit ederek neredeyse mükemmel iş yükü dengesi ve minimum mesaj sayısı elde eder; AHE bu dengenin bir kısmını uyum yeteneği için takas eder.

d) *Etki büyüklükleri*.: Küçük hücreler anlamlılık testlerinin gücünü sınırladığından Cliff  $\delta$  raporluyoruz (Tablo X; işaret,  $\delta > 0$  her zaman AHE lehine olacak biçimde normalize edilir). Örüntü mekanizmayla örtüşür: AHE-MRTA, BiG-MRTA’ya karşı tamamlamada büyük *lehte* etkiler gösterir (*mixed\_stress* ve *deadline\_pressure*’da  $\delta = +1.00$ , *robot\_failure*’da  $+0.60$ ) ve *robot\_failure*’da uzlaşma temel yöntemlerine karşı deadline uyumunda (Cons-DBTA’ya karşı DVR  $\delta = +0.68$ , RoSTAM-EA’ya karşı  $+1.00$ ). Büyük *aleyhte* etkiler ise commit-once temel yöntemlerine karşı toparlanma süresinde (*robot\_failure*’da BiG-MRTA’ya karşı RecT  $\delta = -0.28$ ) ve görevleri terk etmenin yan ürünü olarak düşük ihlal sayısına




Fig. 6. Bir *mixed\_stress* örneğinde (5 robot / 25 görev, tohum 1) dört tahsis yöntemi (AHE-MRTA, Consensus-DBTA, BiG-MRTA, RoSTAM-EA; sol üstten saat yönünde) altında yürütülen robot yörüngeleri. (a) *obstacle\_map* işgal haritası. (b) AHE-MRTA ve Consensus-DBTA filoyu tüm noktaları kapsayacak şekilde yayar; commit-once BiG-MRTA arenanın daha çoğunu kapsamasız bırakır.

TABLE VIII

DEADLINE SCENARIO RESULTS (DEADLINE\_PRESSURE) AT THE PRIMARY 5-ROBOT / 25-TASK SCALE;  $n=5$  RUNS (SEEDS) PER CELL. DVR: DEADLINE VIOLATION RATE. SIGNIFICANCE VS AHE-MRTA\* (BONFERRONI-CORRECTED MANN-WHITNEY U).

| Method           | CR $\uparrow$                       | Delay $\downarrow$ (s)           | DVR $\downarrow$                    | Preempt $\downarrow$ |
|------------------|-------------------------------------|----------------------------------|-------------------------------------|----------------------|
| <b>AHE-MRTA*</b> | <b>1.000 <math>\pm</math> 0.000</b> | 79.4 $\pm$ 10.4                  | 0.360 $\pm$ 0.102                   | 0.00 $\pm$ 0.00      |
| BiG-MRTA         | 0.736 $\pm$ 0.088                   | 260.1 $\pm$ 71.6                 | <b>0.272 <math>\pm</math> 0.072</b> | 0.00 $\pm$ 0.00      |
| RoSTAM-EA        | <b>1.000 <math>\pm</math> 0.000</b> | 74.4 $\pm$ 12.3                  | 0.400 $\pm$ 0.123                   | 0.00 $\pm$ 0.00      |
| Cons-DBTA        | <b>1.000 <math>\pm</math> 0.000</b> | <b>67.2 <math>\pm</math> 4.2</b> | 0.320 $\pm$ 0.130                   | 0.00 $\pm$ 0.00      |

sahip BiG-MRTA'ya karşı DVR'de (*deadline\_pressure*'da  $\delta=-0.56$ ) yoğunlaşır. Düzeltilmiş yeniden-gönderim churn metriğinde AHE rekabetçi-ila-daha-iyidir (*robot\_failure*'da RoSTAM-EA'ya karşı  $\delta=+0.76$ , Cons-DBTA'ya karşı  $+0.64$ ). Bu, merkezi takası niceler: AHE tamamlama ve karar doğruluğunda kazanır, toparlanma gecikmesinde kaybeder.

e) *İstatistiksel anlamlılık.*: 5-robot birincil ölçekte (hücre başına  $n=5$ ) hiçbir karşılaştırma Bonferroni düzeltmesini geçmez:  $n=5$  ile ulaşılabilen en küçük iki-yönlü Mann-Whitney  $p$  değeri ( $\approx 0.008$ ) düzeltilmiş eşiği ( $0.05/21 \approx 0.0024$ ) zaten aşar, yani ölçek yapısal olarak yetersiz güçlüdür (63 karşılaştırmanın 18'i ham  $p < 0.05$ 'e ulaşır). İstatistiksel güç 3-robot ölçeğindedir (hücre başına  $n=15$ ): orada 63 karşılaştırmanın 14'ü aynı yönelimle düzeltmeyi geçer; 10-robot ölçeğinde ( $n=5$ ) yine hiçbirini geçmez. Bu nedenle Gazebo kıyaslamasını *gerçekçi yürütme gürültüsü altında doğrulama* olarak ele alıyor ve birincil hipotez testi için 100-tohumlu tahsis-uygunluk karşılaştırmasına (Bölüm V) güveniyoruz. Tutarlı etki-büyüklüğü örüntüsü (Tablo X) uygunluk sıralamasını destekler.

f) *5 ve 10 robotla fiziksel doğrulama.*: 10-robot Gazebo kıyaslaması (60 deneyin 59'u tamamlandı; Şekil 8) AHE-MRTA'nın her senaryoda en yüksek — ya da berabere-en-yüksek — tamamlama oranına ulaştığını gösterir. *robot\_failure*'da tamamlamada (CR = 0.996, 49.8/50 görev), ihlal oranında (DVR = 0.024) ve medyan makespan'de (299 s; Cons-DBTA 387 s) öne geçer. *deadline\_pressure*'da **CR = 1.000**'e DVR = 0.236 ile ulaşır ve en yüksek zamanında-etkin tamamlamayı verir (CR $\times$ (1-DVR)  $\approx 0.76$ ; Cons-DBTA  $\approx 0.60$ , RoSTAM-EA  $\approx 0.50$  — bunlar CR = 0.968/0.984'e ancak




Fig. 7. En büyük (10-robot) dağıtımın AHE-MRTA altında bir *dynamic\_task\_arrival* örneğinde koşma anında alınmış canlı anlık görüntüsü. **(a)** Gazebo Harmonic 3B fizik: on TurtleBot3 Waffle Pi robotu (mavi) 20×20 m denetim arenasına—bölme duvarları, kare sütunlar ve silindir engeller (turuncu)—dağılmış, her biri atanmış bir denetim noktasına ilerliyor. **(b)** Eşzamanlı RViz görünümü (paylaşılan harita çerçevesinde): önceden oluşturulmuş işgal haritası, her robotun güncel Nav2 küresel planı (robot başına bir renk) ve ground-truth pozuyla bindirilmiş. Renk-kodlu planlar filonun her iki şeride yayıldığını gösterir—ekosistemin olay-başına, iş-koruyan dağıtımının görsel imzası.

TABLE IX

VERİMLİLİK METRİKLERİ (GAZEBO, 3 ROBOT, 15 GÖREV, 5 TOHUM). WLBAL: JAIN İŞ YÜKÜ DENGESİ; LAT: ORTALAMA KARAR GECİKMESİ; MSGS: TAHSİS MESAJLARI; DIST: TOPLAM YOL MESAFESİ.

| Method                            | WLBal↑       | Lat↓(ms)    | Msgs↓    | Dist↓(m)    |
|-----------------------------------|--------------|-------------|----------|-------------|
| <i>Senaryo: robot_failure</i>     |              |             |          |             |
| <b>AHE-MRTA*</b>                  | 0.281        | 0.18        | 38       | 122.5       |
| BiG-MRTA                          | 0.481        | <b>0.12</b> | 121      | <b>71.3</b> |
| RoSTAM-EA                         | <b>0.550</b> | 31.05       | <b>2</b> | 83.3        |
| Cons-DBTA                         | 0.465        | 0.23        | 11       | 89.1        |
| <i>Senaryo: mixed_stress</i>      |              |             |          |             |
| <b>AHE-MRTA*</b>                  | 0.268        | 0.21        | 33       | 110.1       |
| BiG-MRTA                          | <b>0.629</b> | <b>0.08</b> | 177      | <b>59.5</b> |
| RoSTAM-EA                         | 0.479        | 25.64       | <b>4</b> | 92.9        |
| Cons-DBTA                         | 0.309        | 0.13        | 10       | 103.0       |
| <i>Senaryo: deadline_pressure</i> |              |             |          |             |
| <b>AHE-MRTA*</b>                  | 0.733        | 0.23        | 26       | 103.0       |
| BiG-MRTA                          | 0.719        | <b>0.08</b> | 181      | <b>42.2</b> |
| RoSTAM-EA                         | 0.666        | 42.46       | <b>1</b> | 78.4        |
| Cons-DBTA                         | <b>0.819</b> | 0.36        | 6        | 81.7        |

DVR = 0.376/0.488 ödeyerek erişir; bu ikisi daha kısa makespan (177–183 s) elde eder ama o yüksek ihlal oranlarıyla). *mixed\_stress*'te AHE tamamlama oranında Cons-DBTA ile berabere en üsttedir (CR = 0.996, 49.8/50 görev) ve en hızlı makespan'e (195 s) sahiptir; zamanında-etkin tamamlaması ( $\approx 0.70$ ) Cons-DBTA ( $\approx 0.64$ ) ve RoSTAM-EA'nın ( $\approx 0.58$ ) üstünde; görev-terk-eden BiG-MRTA düşük DVR'ı yalnızca çok daha az görev tamamladığı için kaydeder (CR = 0.724). Üç senaryo havuzlandığında AHE-MRTA tamamlama oranı (0.997), tamamlanan görev (49.9/50, en düşük varyans) ve genel makespan'de öndedir. 5-robot kıyaslaması robot-arızası örüntüsünü yansıtır (CR = 1.000, DVR = 0.008) ve *deadline\_pressure*'da BiG-MRTA'nın 0.736'sına karşı CR = 1.000'e ulaşır; ancak orada AHE'nin DVR'ı (0.360) toparlanma-yetenekli yöntemlerle (0.320–0.400) aynı düzeydedir. Karar gecikmesi her iki ölçekte milisaniye-altı kalır (5r'de 0.27–0.30 ms, 10r'de 0.43–0.46 ms) — 10 robotta 55–104 ms'ye büyüyen RoSTAM-EA'dan  $\approx 120$ – $240\times$  daha hızlı.

TABLE X  
ETKİ BÜYÜKLÜKLERİ (CLIFF  $\delta$ ): AHE-MRTA\* VS HER TEMEL YÖNTEM, BİRİNCİL METRİKLER.  $\delta > 0$  AHE-MRTA\* LEHİNE. \* $p < 0.05$  (DÜZELTİLMEMİŞ MANN-WHITNEY U).

| Metric                            | vs       | BiG   | RoSTAM | Cons-DBTA |
|-----------------------------------|----------|-------|--------|-----------|
| <i>Senaryo: robot_failure</i>     |          |       |        |           |
| CR                                | $\delta$ | +0.60 | +0.00  | +0.00     |
| DVR                               | $\delta$ | +0.48 | +1.00  | +0.68     |
| RecT                              | $\delta$ | -0.28 | +0.36  | +0.44     |
| Churn                             | $\delta$ | -0.08 | +0.76  | +0.64     |
| <i>Senaryo: mixed_stress</i>      |          |       |        |           |
| CR                                | $\delta$ | +1.00 | +0.00  | +0.00     |
| DVR                               | $\delta$ | +0.40 | +0.28  | +0.92     |
| RecT                              | $\delta$ | -0.28 | -0.36  | +0.20     |
| Churn                             | $\delta$ | +0.44 | +0.92  | +0.92     |
| <i>Senaryo: deadline_pressure</i> |          |       |        |           |
| CR                                | $\delta$ | +1.00 | +0.00  | +0.00     |
| DVR                               | $\delta$ | -0.56 | -0.00  | -0.08     |
| RecT                              | $\delta$ | -0.00 | -0.00  | -0.00     |
| Churn                             | $\delta$ | -0.00 | -0.00  | -0.00     |

Pozitif  $\delta$  = AHE-MRTA\* daha iyi;  $|\delta| > 0.47$  = büyük etki.




Fig. 8. 10-robot ölçeğinde çok-metrikli karşılaştırma (60 deney: 4 yöntem  $\times$  3 senaryo  $\times$  5 tohum, senaryolar havuzlanmış; karar gecikmesi log ölçek). AHE-MRTA her senaryoda en yüksek tamamlama oranına ulaşır (deadline baskısında CR = 1.000, robot arızası ve karışık strese 0.996) ve havuzlanmış en yüksek zamanında-etkin tamamlamayı verir; EDF temel yöntemleri benzer CR'ye ancak çok daha yüksek deadline ihlal oranlarıyla erişir (DVR = 0.38–0.49 vs. AHE'nin bu senaryolardaki 0.20–0.32'si). Milisaniye-altı gecikme ( $\leq 0.48$  ms) 10 robotta korunur.

## VII. TARTIŞMA

### A. İdeal-uygunluk neden Gazebo'ya doğrusal aktarılmıyor?

100-tohumlu tahsis-uygunluk simütörü Nav2 maliyet varyansını (yerel planlayıcı duraklamaları, costmap yeniden inşaları, dar koridorlarda geçiş manevraları) kaldırır, böylece her kararın değeri tam olarak gerçekleşir. Gazebo'da iki etki AHE'nin avantajını azaltır:

- 1) **Geçiş maliyeti fiziksel olarak gerçekleşir.** Bir AHE paradigma geçişi, önceki paradigmanın zaten yönlendirdiği bir görevi yeniden atayabilir; alan robot mevcut yolunu iptal etmeli, Nav2'den yeni plan istemeli ve




Fig. 9. Birincil 5-robot / 25-görev ölçeğinde çok-metrikli karşılaştırma (Gazebo, robot\_failure + mixed\_stress senaryoları havuzlanmış, hücre başına  $n=5$  tohum, ortalama  $\pm$  std): tamamlama oranı, tamamlanan görev, ortalama gecikme, iş yükü dengesi (Jain), deadline ihlal oranı ve karar gecikmesi (log ölçek). Commit-once temel yöntemleri hiç yeniden yönlendirme yapmayarak daha yüksek havuzlanmış CR ve daha düşük gecikme elde eder; BIG-MRTA'nın düşük DVR'ı terk edilen görevleri yansıtır (en düşük CR). AHE-MRTA gecikmeyi reaktif yeniden tahsisle takas eder; bu, büyük ölçeklerde karşılığını verir (Şekil 8).




Fig. 10. Birincil 5-robot / 25-görev ölçeğinde robot\_failure altında arıza-toparlanma davranışı ( $n=5$  tohum, ortalama  $\pm$  std): toparlanma süresi, tamamlama oranı ve yeniden-gönderim oranı (yürütme kesintileri tüm yöntemlerde sıfır olduğundan gösterilmedi). Toparlanma süreleri yöntemler arasında istatistiksel olarak ayırt edilemez ( $p>0.3$ ); AHE-MRTA, karşılaştırılabilir toparlanma süresini bir ekosistem güncelleme çevrimi içinde ( $\leq 2$  s) yetim-kurtarma paradigmasına geçerek reaktif yöntemlerin en yüksek tamamlama oranına çevirir.

yeniden katetmelidir. Tek seferde commit edip kalan uzlaşma temel yöntemleri böyle bir yeniden planlama yükü ödemez; AHE'nin olay-tetikli yeniden-değerlendirmesi ise ara sıra canlı bir görevi yeniden yönlendirir.

- 2) **Makespan fiziksel yürütmeye baskındır.** Nav2 bir robotu görevlendirdiğinde, o görevin makespan katkısı tahsis tarafından değil dünya geometrisi tarafından sabitlenir. AHE'nin ek yeniden planlaması en kötü durum yolunu belirgin biçimde uzatır.

Gazebo verisi bununla tutarlıdır: AHE'nin CR ve DVR'ı (hızlı yürütmeyi değil doğru kararları ödüllendirir) en güçlü temel yöntemlerle eşleşirken, makespan ve kararsızlık (yeniden planlamayı cezalandırır) sabit-commit temel yöntemlerinin gerisinde kalır.






Fig. 11. *robot\_failure* altında yorumlanabilir uyum (3r/15g). (a) Temsili bir AHE-MRTA koşusunun hormon baskınlığı; arıza enjeksiyonunda (noktalı çizgi,  $t \approx 75$  s) toparlanma hormonu geçici bir yükseliş gösterir, ancak bu temsili koşu boyunca uzamsal paradigma baskın kalır. (b) Kümülatif görev tamamlama (tohum-ortalama); noktalı çizgi: medyan enjeksiyon  $t \approx 164$  s): AHE-MRTA arızadan sonra tamamlamaya devam eder ve tam görev kümesine ulaşır. (c-e) Toparlanma süresi, ortalama görev gecikmesi ve görev yeniden-gönderim oranı kutu grafikleri (kutü: IQR; çizgi: medyan; bıyıklar:  $1.5 \times \text{IQR}$ ; noktalar: tekil koşular, yöntem başına  $n=15$ ): AHE'nin reaktifliği, commit-once temel yöntemlerine kıyasla daha yüksek görev gecikmesi ve yeniden-gönderim maliyeti taşır.




Fig. 12. 3-robot ölçeğinde zaman içinde kümülatif görev tamamlama, üç görev yoğunluğu üzerinden tohum-ortalama: (a) *robot\_failure*, (b) *mixed\_stress*. AHE-MRTA her iki senaryoda tam görev kümesini tamamlar ve konsensüs temel yöntemlerini yakından izler; Nav2 üzerinden yeniden atamanın getirdiği makespan farkı ölçülüdür (*mixed\_stress*: 238 s; Cons-DBTA 217 s, RoSTAM-EA 231 s). BiG-MRTA uygunsuz işaretlediği görevleri terk eder ve tam kümenin altında biter (Bölüm VII).

### B. Paradigma değiştirme ne zaman işe yarar?

Verimizden ampirik yanıt:

- **Deadline uyumu ham kapsamadan daha önemli olduğunda.** *deadline\_pressure*'da konsensüs ve evrimsel temel yöntemler AHE'nin tamamlamasına ancak deadline ihlal oranının  $1.6-2.1 \times$  katıyla erişir (10r: AHE DVR = 0.236 vs Cons-DBTA 0.376 ve RoSTAM-EA 0.488); böylece AHE en yüksek zamanında-etkin tamamlamaya ulaşır ( $\approx 0.76$ ). Aynı örüntü 3 robotta *mixed\_stress*'te de görülür (DVR 0.38 vs Cons-DBTA 0.44); 10 robotta AHE en yüksek ham CR'yi (0.996) korur ve zamanında-etkin tamamlaması Cons-DBTA ile aynı düzeydedir.
- **Arızalar çok sayıda görevi yetim bıraktığında.** *robot\_failure* altında 5 ve 10 robotta AHE, en yüksek tamamlamayı (5r'de CR = 1.000, 10r'de 0.996) DVR  $\leq 0.024$  ile birleştirir; yetim-kurtarma paradigması arızalı robotun kuyruğunu bir ekosistem çevrimi içinde yeniden dağıtır.
- **Tek bir rejim tüm koşuya baskınken ve amaç makespan iken değil.** 3 robotta tekdüze deadline baskısı altında EDF-tarzı uzmanlar zaten tama-yakın tamamlamaya ulaşır (RoSTAM 0.985, Cons-DBTA 0.978, AHE

TABLE XI

EDPS ABLASYONU (NAV2-BAĞIMSIZ UYGUNLUK, 5R/25G, 100 SEED). TÜM VARYANTLAR 0.9 PP MEAN-UYGUNLUK İÇİNDE; HİÇBİRİ EDPS'TEN İSTATİSTİKSEL AYRIŞMIYOR.

| Varyant           | Rob. arı. | Deadline | Kar. stres | Ort.  |
|-------------------|-----------|----------|------------|-------|
| Tam EDPS          | 0.538     | 0.483    | 0.538      | 0.520 |
| sabit: spatial    | 0.552     | 0.482    | 0.549      | 0.528 |
| sabit: edf        | 0.544     | 0.489    | 0.540      | 0.524 |
| sabit: commit     | 0.547     | 0.474    | 0.549      | 0.523 |
| sabit: orphan     | 0.537     | 0.481    | 0.541      | 0.520 |
| sabit: priority   | 0.542     | 0.478    | 0.537      | 0.519 |
| no-override       | 0.538     | 0.483    | 0.538      | 0.520 |
| no-recovery-boost | 0.537     | 0.483    | 0.539      | 0.519 |

1.000); dolayısıyla AHE'nin geçişleri onlara karşı anlamlı bir tamamlama üstünlüğü sağlamaz, yalnız gecikme ekler; katı zamanında-uygunlukta AHE bu ölçekte BiG-MRTA ile aynı düzeydedir (0.459 vs 0.458). AHE'nin ham-CR avantajı yalnızca görev-terk-eden commit-once politikasına karşıdır (BiG 0.636). Ancak 10 robotta AHE, uzmanların 0.376–0.488'ine karşı DVR'ı 0.236'da tutar ve en yüksek zamanında-etkin tamamlamaya ulaşır (Bölüm VI).

### C. AHE neden domine etmek yerine uygunlukta eş-liderlik yapıyor

Nav2-bağımsız uygunlukta (öncelik-ağırlıklı zamanında tamamlama) AHE-MRTA ve Consensus-DBTA, biri diğerini domine etmek yerine istatistiksel eş-liderdir (Tablo V). En güçlü yöntemlerin neden yakınsadığını iki mekanizma açıklar. Birincisi, uygunluk tavanı atama kalitesiyle değil *stokastik, pozisyona-bağlı navigasyon arızasıyla* belirlenir: idealize kusursuz-navigasyon modelinde her yöntem tüm görevleri zamanında tamamlar (uygunluk  $\approx 1.0$ , yüksek görev yoğunluğunda bile), ve yöntemler arası fark yalnız hedefler başarısız olup yeniden denenmek zorunda kalınca açılır. Bağlayıcı kısıt dolayısıyla navigasyon arızasına dayanıklılıktır—AHE-MRTA ve Consensus-DBTA'nın ikisi de başarısız ve yetim görevleri yeniden göndererek uyguladığı bir yetenek—bu yüzden ikisi aynı sınıra yakınsar, başarısız görevleri terk eden commit-once BiG-MRTA ise geride kalır. İkincisi, metrik bir görevi yalnız deadline'ından *önce* bitince ödüllendirir; geç tamamlama tıpkı bitmemiş gibi sıfır kredi alır. AHE'nin bütünlük-odaklı ilkeleri süresi geçen görevleri yeniden göndermeye devam eder, böylece nihayet biterler—ham tamamlamayı ve dayanıklılığı yükseltir—ama bir kısmı *geç* tamamlanır ve zamanında-kredi kazanamaz; commit-once temel yöntem ise bu görevleri terk eder, dolayısıyla tamamladığı azı zamanındadır. Bu bilinçli *bütünlük-over-dakiklik* takası, AHE'nin fiziksel yığındaki tamamlama, sıfır-yetim davranışını üretir (Bölüm VI). Deadline-fizibilite-duyarlı bir yürütme sıralamasının AHE'yi eş-liderlerin önüne taşıyıp taşıyamayacağını da inceledik: izole olarak deadline uygunluğunu  $\approx 1.3$  pp yükseltir, ama bağlam sinyalleriyle kapılandığında throughput-bağlı karışık rejimde de tetiklenir ve uygunluğu benzer bir marjla düşürür (Pareto kuplağı). Bu yüzden daha basit bütünlük-odaklı politikayı koruruz; eş-lider uygunluğu ve belirleyici fiziksel-yığın üstünlükleri daha güçlü işletim noktasıdır.

### D. Ablasyon: switching makinesi ne katıyor?

Online paradigma-değişiminin katkısını yalıtmak için EDPS seçiciyi her bir *sabit* paradigma ile değiştiriyoruz; ayrıca bağlam override'larını (*no-override*:  $\text{saf arg max}_i D_i$ ) ve recovery boost'u (*no-recovery-boost*:  $\delta=0$ ) gerisini sabit tutarak kapatıyoruz (5r/25g, 100 seed, `scripts/ablation_edps.py`).

Sekiz varyant yalnız [0.519, 0.528] mean-uygunluk aralığına yayılıyor (yayılım 0.009, bir std sapmanın çok altında): *hiçbir* konfigürasyon tam EDPS'ten ayrışmıyor, override'ları veya recovery boost'u kaldırmak Plane-A uygunluğunu neredeyse değiştirmiyor. Bu, yukarıda saptanan doyunluğun (mükemmel navigasyonla her yöntem  $\approx 1.0$ ) beklenen sonucu: navigasyon- bağımsız düzlemde tahsis kalitesi ayırt edici değildir, dolayısıyla switching makinesi onu iyileştiremez. EDPS'in değeri bu nedenle idealize tahsis uygunluğunda değil, fiziksel-yığın davranışındadır (Bölüm VI). Bu ablasyonu gizlemek yerine açıkça raporluyoruz: katkının *nerede* olduğunu dürüstçe sınırlandırır.

### E. Haberleşme ayak izi

AHE-MRTA yalnızca robot başına optimize görev kuyrukları yayınlar; baskınlık vektörü, işbirliği/baskılama matrisleri ve global maliyet matrisi ekosistem yöneticisini asla terk etmez. Şekil 13 sonuç mesaj ayak izinin kompakt kaldığını ve paradigma değiştirme sıklığıyla büyümediğini gösterir; bu da saha dağıtımı için gereken düşük-bant-genişliği özelliğini korur.




Fig. 13. Tahsis olayı başına haberleşme ayak izi. Yalnızca robot başına kuyruklar yayınlanır; ekosistem içsel durumları yerel kalır, bant genişliğini sınırlı tutar.

### F. Sınırlılıklar

(i) **Birincil ölçekte istatistiksel güç:** 5-robot birincil ölçekte (hücre başına  $n=5$ ) hiçbir karşılaştırma Bonferoni düzeltmesini geçmez — $n=5$  yapısal olarak yetersiz güçlüdür—; 3 robotta ( $n=15$ ) ise 63 karşılaştırmanın 14’ü geçer; 10 robotta hücre başına beş tohum benzer biçimde yetersiz güçlüdür ve hiçbir karşılaştırma düzeltmeden sağ çıkmaz. Birincil hipotez testi olarak 100-tohumlu Nav2-bağımsız uygunluğu ve örnekleme-dayanıklı ölçü olarak Cliff  $\delta$ ’yı raporlayarak hafifletiyoruz; daha büyük bir 10-robot tohum bütçesi ek çıkarımsal destek sağlar. (ii) **Toparlanma süresi varyansı:** *mixed\_stress* toparlanma süresi yüksek varyans taşır (10r:  $72 \pm 78$  s) çünkü bazı tohumlarda gözlem penceresinde arıza oluşmaz; garanti pencere-içi arızalı *robot\_failure* senaryosu daha temiz toparlanma ölçüsüdür. (iii) **Donanım-bağlı ölçek tavanı:** 15 robota ölçeklemek 16-çekirdek/ 15 GB test düzeneğimizde uygulanamazdı—çok sayıda robot-başına Nav2 yığını başlatmada hazır-olma denetiminden geçemedi (başlatma hataları)—bu yüzden 10 robot en büyük *doğrulanmış* fiziksel ölçektir. Bu, simülasyon ana makinesinin hesaplama limitidir, algoritmik değil; Nav2-bağımsız düzlem tahsis politikasının daha ileri ölçeklendiğini doğrular. (iv) **Arena genişliği:** Tüm deneyler tek bir yerleşim kullanır; ortamlar-arası genelleme gösterilmemiştir. (v) **Sabit hormon-paradigma eşlemesi:**  $A$ ,  $S$  ve  $V$  matrisleri tasarımcı-tanımlıdır; bunları veriden öğrenmek gelecek çalışmaya bırakılmıştır. (vi) **Tek-tip robot yeteneği:** Tüm robotlar özdeştir (ST-SR); heterojen-yetenekli filolar değerlendirilmemiştir. (vii) **Ground-truth yerelleştirme:** Fiziksel kıyaslama, pozu başlangıç pozuna sabitlenmiş statik bir *map*→*odom* dönüşümüyle sağlar ve tahsis kalitesini yerelleştirme hatasından kasıtlı olarak yalıtır. Gerçek konuşlandırmalarda yerelleştirme kayması olur; katkı tahsis politikası olduğundan ve her yöntem aynı ground-truth pozu paylaştığından kıyaslama adil kalır, ancak yerelleştirme gürültüsüne (örn. AMCL) dayanıklılığın ölçülmesi gelecek çalışmaya bırakılır. (viii) **Hormon dinamiğinin sınırlı rolü.** Değerlendirilen stres senaryolarında belirlenimci bağlam geçersiz-kılmaları (Bölüm III) akut olayları—robot arızası ve deadline baskısı—çözdüğünden, Lotka-Volterra dinamiği her kararda değil esas olarak daha düşük-baskılı kalan olaylarda etkindir. Bu nedenle EDPS’i yalnızca-dinamik bir seçici olarak değil, uyarlanır dinamik katman *olan* bağlam-güdümlü bir override cascade olarak çerçevesiyoruz. Tablo XI’deki ablasyon (Bölüm VII-D) bunu doğrular: override’ları veya recovery boost’u kaldırmak ve seçiciyi herhangi bir tek-sabit paradigmayla değiştirmek, Plane-A uygunluğunu EDPS’in 0.9 pp içinde bırakır. Switching makinesinin değeri böylece navigasyon-bağımsız düzleme değil, fiziksel yığına (Plane B) özgüdür. (ix) **Tahsis-uygunluk modeli.** Plane-A simülatörü, tahsis dayanıklılığını *zorlamak* için pozisyon-bağımlı bir navigasyon-başarısızlık modeli kullanır; başarısızlık oranı, gerçek Gazebo yığımından (Nav2 hedeflere neredeyse her zaman ulaşır) kasıtlı olarak yüksektir. Bu nedenle Plane A mutlak başarı oranını değil, göreceli tahsis dayanıklılığını ölçer ve fiziksel Plane-B sonuçlarının yerine değil, yanında raporlanır.

## VIII. SONUÇ

Çevrim içi çoklu robot görev atama için ekosistem-güdümlü paradigma-değiştiren bir çerçeve olan AHE-MRTA’yı sunduk. 100-tohumlu Nav2-bağımsız simülasyonda AHE-MRTA ve en güçlü konsensüs temel yöntemi (Consensus-DBTA) istatistiksel eş-liderdir—AHE *deadline\_pressure*’da birinci, *robot\_failure*’da eşit, *mixed\_stress*’te 0.001 geride—ve AHE bir ölçeklenebilirlik taramasında genel uygunluk önderliğini on robota kadar korur. TurtleBot3 robotları üzerinde ROS 2 Jazzy ve Nav2 ile 300-deneylik Gazebo Harmonic kıyaslamasında (3r, 5r ve 10r fiziksel ölçekler) AHE-MRTA, robot arızası altında tamamlama oranında öndedir (5r’de  $CR = 1.000$ , 10r’de 0.996;  $DVR = 0.008/0.024$ ) ve 10 robotta her senaryoda en yüksek tamamlama oranına ulaşır ( $CR = 0.996-1.000$ ); konsensüs ve evrimsel temel yöntemler, deadline baskısı altında onun tamamlamasına yalnızca  $\approx 1.9\times$  daha yüksek deadline ihlal oranıyla erişir ( $DVR = 0.38-0.49$  vs AHE’nin 0.24’ü). Milisaniye-altı karar gecikmesi tüm ölçeklerde korunur ( $\leq 0.48$  ms; RoSTAM-EA’dan  $\approx 125-280\times$  daha hızlı); bunun bedeli, sabit-commit uzlaşma yöntemlerine kıyasla karışık-stres koşullarında daha yüksek makespan

ve görev gecikmesidir. İdeal tahsis uygunluğu ile gerçekleşen Gazebo metrikleri arasındaki bu ayrıştırmanın, algoritma kalitesini fiziksel yürütme gürültüsünden ayırmaya çalışan diğer MRTA çalışmalarına faydalı olmasını umuyoruz.

## REFERENCES

- [1] F. Zitouni, R. Maamri, and S. Harous, "Towards a formal analysis of the multi-robot task allocation problem using set theory," *Bulletin of Electrical Engineering and Informatics*, vol. 10, no. 2, pp. 1092–1104, 2021.
- [2] T. Lei, P. Chintam, and C. Luo, "A convex optimization approach to multi-robot task allocation and path planning," *Sensors*, vol. 23, no. 11, p. 5103, 2023.
- [3] H. Aziz, H. Chan, and Á. Cseh, "Multi-robot task allocation – complexity and approximation," *arXiv preprint arXiv:2103.12370*, 2021.
- [4] S. Choudhury, J. K. Gupta, and M. J. Kochenderfer, "Dynamic multi-robot task allocation under uncertainty and temporal constraints," *Autonomous Robots*, vol. 46, no. 1, pp. 231–247, 2021.
- [5] S. Park, Y. D. Zhong, and N. E. Leonard, "Multi-robot task allocation games in dynamically changing environments," in *Proc. IEEE Int. Conf. Robotics and Automation (ICRA)*, 2021, pp. 8678–8684.
- [6] F. Quinton, C. Grand, and C. Lesire, "Communication-preserving bids in market-based task allocation," in *Proc. IEEE/RSJ Int. Conf. Intelligent Robots and Systems (IROS)*, 2022, pp. 13 708–13 713.
- [7] A. Milot, E. Chauveau, and S. Lacroix, "Market-based multi-robot coordination with HTN planning," in *Proc. IEEE/RSJ Int. Conf. Intelligent Robots and Systems (IROS)*, 2021, pp. 2606–2612.
- [8] M. Al-Shaboti and U. Baroudi, "Multi-robot task allocation system: Fuzzy auction-based and adaptive multi-threshold approaches," *SN Computer Science*, vol. 2, no. 2, p. 110, 2021.
- [9] P. Ghassemi and S. Chowdhury, "Multi-robot task allocation in disaster response: Addressing dynamic tasks with deadlines and robots with range and payload constraints," *Robotics and Autonomous Systems*, vol. 147, p. 103905, 2022.
- [10] J. García Martín, M. Hanif, and T. Hatanaka, "Predictive receding-horizon multi-robot task allocation with moving tasks," in *Proc. European Control Conference (ECC)*, 2022, pp. 2030–2035.
- [11] P. Mahato, S. Saha, and C. Sarkar, "Consensus-based fast and energy-efficient multi-robot task allocation," *Robotics and Autonomous Systems*, vol. 159, p. 104270, 2023.
- [12] A. Ozalp, E. Cevikan, and S. I. Satoglu, "On-line task allocation for multi-robot teams under dynamic scenarios," *Intelligent Decision Technologies*, vol. 18, no. 1, pp. 1–18, 2024.
- [13] A. Khamis, A. Hussein, and A. Elmogy, "Multi-robot task allocation: A review of the state-of-the-art," in *Cooperative Robots and Sensor Networks*. Springer, 2015, pp. 31–51.
- [14] A. Tariq, H. Masood, S. A. Alsuhbany, and A. Jalal, "Deadline-aware task allocation for heterogeneous robot teams in dynamic environments," *IEEE Access*, vol. 11, pp. 45 821–45 835, 2023.
- [15] V. A. Santos, M. Sarcinelli-Filho, and R. Carelli, "Resilient task allocation for mobile robot teams with fault tolerance via hybrid auction-based mechanism," *Robotics and Autonomous Systems*, vol. 145, p. 103868, 2021.
- [16] B. Peng, X. Zhang, and M. Shang, "A novel competition-based coordination model with dynamic feedback for multi-robot systems," *IEEE/CAA Journal of Automatica Sinica*, vol. 10, no. 10, pp. 2029–2031, 2023.
- [17] E. K. Burke, M. Hyde, G. Kendall, G. Ochoa, E. Özcan, and J. R. Woodward, "A classification of hyper-heuristic approaches: Revisited," in *Handbook of Metaheuristics*. Springer, 2013, pp. 449–474.
- [18] A. Dutta and S. Bhattacharyya, "Task allocation in multi-agent systems using contract-net protocol with adaptive bid generation," *Intelligent Decision Technologies*, vol. 13, no. 2, pp. 209–219, 2019.
- [19] H.-L. Choi, L. Brunet, and J. P. How, "Consensus-based decentralized auctions for robust task allocation," *IEEE Transactions on Robotics*, vol. 25, no. 4, pp. 912–926, 2009.
- [20] L. Zhang, F. Long, and J. Xiao, "Auction-based online task allocation with deadlines for multi-robot systems," *IEEE Robotics and Automation Letters*, vol. 8, no. 4, pp. 2108–2115, 2023.
- [21] F. Tang, J. Li, and M. Tang, "Context-aware multi-robot task allocation using graph attention networks," *IEEE Transactions on Automation Science and Engineering*, vol. 20, no. 4, pp. 2451–2464, 2023.
- [22] N. Koenig and A. Howard, "Design and use paradigms for Gazebo, an open-source multi-robot simulator," in *Proceedings of IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2004, pp. 2149–2154.
- [23] S. Macenski, T. Foote, B. Gerkey, C. Lalancette, and W. Woodall, "Robot operating system 2: Design, architecture, and uses in the wild," in *Science Robotics*, vol. 7, no. 66, 2022, p. eabm6074.
- [24] S. Macenski, F. Martín, R. White, and J. G. Clavero, "The marathon 2: A navigation system," in *Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2020, pp. 2718–2725.
- [25] ROBOTIS, "TurtleBot3 platform for ROS 2 navigation benchmarks," ROBOTIS e-Manual, 2023, [Online; accessed 2026]. [Online]. Available: <https://emanual.robotis.com/docs/en/platform/turtlebot3/overview/>